拼音文本詞彙統計工具 使用說明 (以哈利波特為例)

1. 載入文本:提供三種文本格式與來源

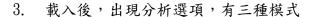
a. 從 DocuSky 匯入:已在 DocuSky 建庫

b. 上傳 xml 檔:本地.xml 檔案 c. 上傳 txt 檔:本地.txt 檔案

拼音文本詞彙統計工具 使用說明 English		
載入文本		
從 DocuSky 載入 上傳 xml 檔 上傳 txt 檔		
Corpus Name - Document Name		

2. 載入後,內文可於黑框中檢視,並使用頁籤切換文件





a. 詞頻:n-gram 分析

b. 詞彙清單:給定詞彙清單進行統計

c. 標記:標記統計



詮釋資料

filename corpus topic title book_code

詞彙統計



詞頻	詞彙清單	標記
文件範圍	e.g. 1,5,6-10 是否使用詞形還 例	Off
詞彙清單	編辑 上傳 (.txt)	開始統計

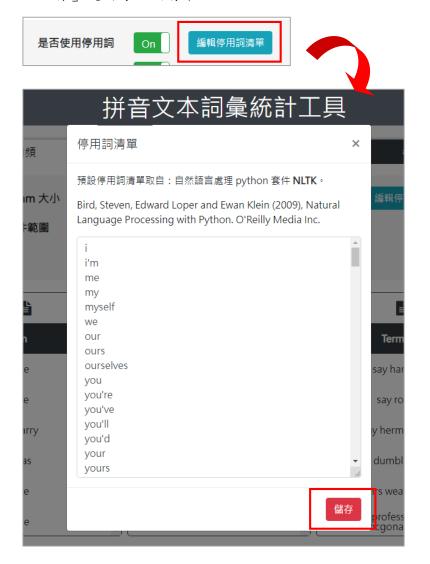
詞頻	詞彙清單	標記
文件範圍	e.g. 1,5,6-10	
標記 Udef_Teacher Udef_sorcery		
開始統計		

4. 調整參數後,按「開始統計」進行分析(第一次跑會套用 NLP 套件,需要較長時間)



可設定參數:

- 文件範圍(全):要統計的文件頁數,預設全部
- N-gram 大小(詞頻): 要統計的 gram 數, 選項 1-5
- 是否使用停用詞(詞頻):去除停用詞再進行統計,stopwords(英文)由
 python NLP 套件提供,按「編輯停用詞清單」可刪減、增加停用詞,按「儲存」更新停用詞清單



- 是否使用詞形還原(詞頻、詞彙清單)(限英文):還原動詞變化、名詞單複數 再進行統計,例:say, says, said, saying => say
- 詞彙清單:欲進行統計的詞彙清單,可按「編輯」手動輸入詞彙,也可直接「上傳(.txt)」的詞彙清單,按「清空」刪除所有詞彙,按「儲存」更新詞彙清單



● 標記:列出抓取到的所有標記名稱,選擇欲進行統計的標記,例子如下圖: 選擇 Udef_Teacher, Udef_sorcery 不選

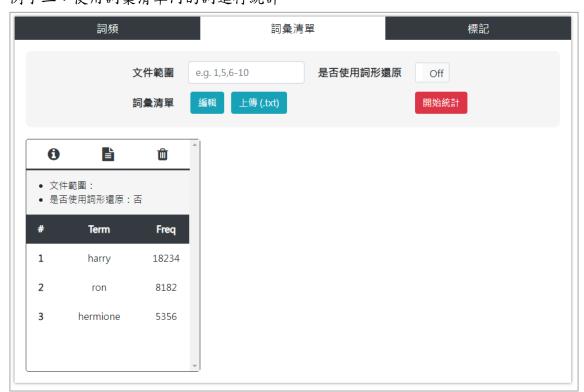


5. 結果顯示在下方,一次分析會產生一個表格

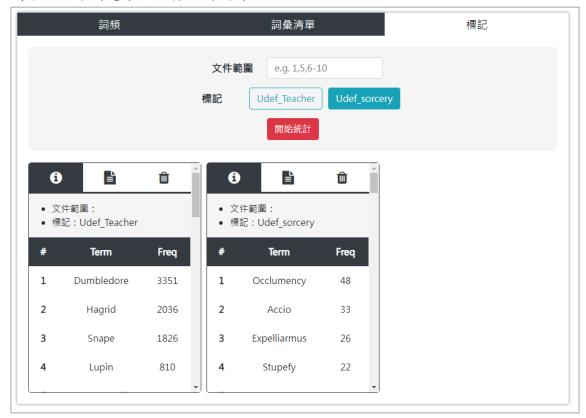
例子一:用不同的參數跑了三次詞頻分析的結果



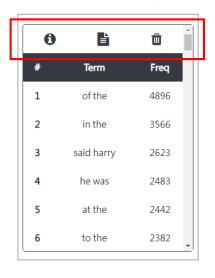
例子二:使用詞彙清單內的詞進行統計



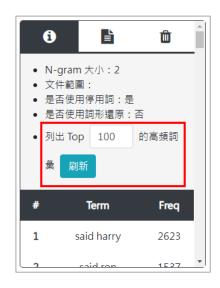
例子三:分別跑了兩個標記的統計



6. 結果表格: 詞彙照出現次數排序, 上方帶有工具列



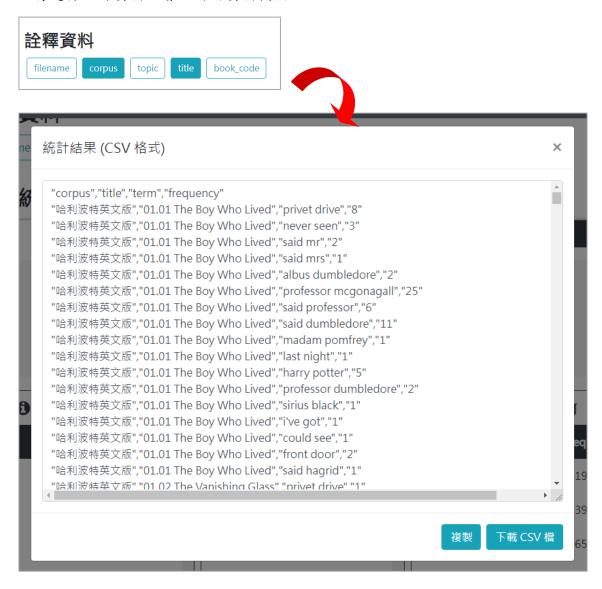
- :刪除此次統計結果



● : CSV 格式的統計結果(以文件為單位),可以「複製」到剪貼簿,或者直接「下載 CSV 檔」



若有選擇詮釋資料,會一併將資料輸出。



7. 可以切換中、英文介面

